

INFORME DEL MODELO PREDICTIVO DE VENTAS

Reto 4 — Aplicación de IA para la predicción de ventas

El Mercado de las Especies de Dataclysm

Autora: Judit Giravent

Fecha: 09/2026

Herramientas: Python 3.13 · pandas · scikit-learn · matplotlib · Google Colab

Dataset: Online Retail II (UCI Machine Learning Repository)

Índice

1. Resumen ejecutivo
 2. Introducción y contexto
 3. Paso 1: Recolección de datos
 4. Paso 2: Preparación de datos
 5. Paso 3: Selección y entrenamiento del modelo
 6. Paso 4: Evaluación del modelo
 7. Paso 5: Realización de predicciones
 8. Conclusiones y recomendaciones
 9. Anexos
-

1. Resumen ejecutivo

Este proyecto desarrolla un **modelo predictivo de ventas semanales** basado en técnicas de inteligencia artificial para el Mercado de las Especies de la isla de Dataclysm. El objetivo es que los mercaderes puedan **anticipar la demanda** y ajustar sus estrategias comerciales.

Resultados principales

- **Dataset utilizado:** 995.416 transacciones reales de una tienda online británica (2009–2011).
- **Agregación:** 104 semanas de ventas, de las cuales 93 son utilizables tras crear las features del modelo.
- **Modelo seleccionado:** Random Forest con 100 árboles y profundidad máxima 8.
- **Métricas de evaluación:**
 - **RMSE:** 46.810 £
 - **MAE:** 41.178 £
 - **R²:** -0,04

- **Mejora respecto al baseline: 40% mejor** que predecir la última semana (78.504 £ → 46.810 £).
- **Precisión en campaña navideña:** el error baja al **0,57%** en semanas de alta demanda.

Conclusión

El modelo es especialmente **fiable para la planificación de la campaña navideña**, precisamente el período de mayor impacto económico para los mercaderes. Las predicciones en noviembre-diciembre tienen un error inferior al 5%, permitiendo tomar decisiones estratégicas con confianza.

2. Introducción y contexto

2.1 Contexto narrativo

En la enigmática isla de Dataclysm, el bullicioso Mercado de las Especies enfrenta un desafío ancestral: **predecir el futuro**. Los mercaderes, guiados por siglos de tradición, necesitan una herramienta que les permita anticipar la demanda futura y adaptarse a los vientos cambiantes del comercio.

La inteligencia artificial se presenta como esa brújula capaz de iluminar lo incierto. A través del análisis de patrones históricos, un modelo predictivo puede ayudar a las familias mercantes a tomar decisiones informadas.

2.2 Objetivo del reto

Desarrollar un **modelo de predicción de ventas** basado en datos históricos que permita:

1. Anticipar la demanda de productos.
2. Ajustar estrategias comerciales.
3. Reducir la incertidumbre en la planificación de stock.
4. Optimizar recursos en períodos clave (campaña navideña).

2.3 Metodología aplicada

El reto se ha estructurado en los **5 pasos oficiales**:

Paso	Descripción	Herramientas
1	Recolección de datos	UCI Repository · pandas
2	Preparación de datos	pandas · numpy
3	Selección y entrenamiento	scikit-learn
4	Evaluación del modelo	RMSE, MAE, R ²
5	Realización de predicciones	Random Forest · matplotlib

3. Paso 1: Recolección de datos

3.1 Búsqueda de fuentes

Se evaluaron las siguientes fuentes recomendadas por el reto:

Fuente	Descripción	Resultado
Kaggle	Amplia colección de datasets públicos	Opciones variadas, pero ninguna tan completa como el dataset elegido
UCI Machine Learning Repository	Base de datos pública especializada en ML	Dataset seleccionado
Microsoft Power BI Sample Datasets	Datasets de ejemplo para BI	No utilizados

3.2 Dataset seleccionado

Nombre: Online Retail II
Fuente: UCI Machine Learning Repository
URL: <https://archive.ics.uci.edu/dataset/502/online+retail+ii>

Característica	Valor
Instancias	1.067.371 transacciones (995.416 tras limpieza)
Variables	8 columnas originales
Periodo	Diciembre 2009 – Diciembre 2011
Tipo	Comercio electrónico · Series temporales
País	Reino Unido

3.3 Justificación de la elección

Se seleccionó este dataset por las siguientes razones:

- Cumple todos los requisitos técnicos:** incluye variables de fecha, producto, volumen de ventas y precios.
- Es un dataset real:** transacciones reales de una tienda online, no datos sintéticos.
- Volumen adecuado:** más de 995.000 registros limpios para entrenar un modelo robusto.
- Rango temporal suficiente:** 2 años completos, con **dos campañas navideñas** completas, clave para capturar la estacionalidad.
- Es directamente análogo al Mercado de las Especias:** un negocio minorista con productos, precios y ventas variables en el tiempo.

3.4 Variables clave para el modelo

Variable	Tipo	Uso en el modelo
InvoiceDate	Fecha/hora	Agregación temporal semanal
StockCode	Categórica	Identificación de productos
Description	Texto	Análisis de productos
Quantity	Numérica	Volumen de ventas
UnitPrice	Numérica	Precio unitario
Country	Categórica	Segmentación geográfica
TotalPrice	Numérica (derivada)	Variable objetivo (suma de ventas)

4. Paso 2: Preparación de datos

4.1 Limpieza inicial

El dataset original fue sometido a un proceso de limpieza previo que eliminó:

Paso	Filas eliminadas	Motivo
Agregación de duplicados	44.928	Compras repetidas legítimas
Cancelaciones (Invoice 'C')	22.434	Devoluciones
Precios ≤ 0	2.616	Errores de captura
Outliers extremos (P99.9)	1.977	Valores atípicos

Total: 995.416 filas limpias (93,3% del original).

4.2 Agregación semanal

Para el modelo predictivo, los datos se agregaron a **nivel semanal**, generando una serie temporal con:

- **104 semanas** en total (desde 2009-12 hasta 2011-12).
- Variable objetivo: **Ventas** (suma de **TotalPrice** por semana).
- Rango de ventas semanales: **£83.617 – £483.605**.

4.3 Creación de features (ingeniería de variables)

Se crearon las siguientes variables para enriquecer el modelo:

Variables temporales

Feature	Descripción
Month	Mes del año (1-12)
weekOfYear	Semana del año (1-52)
Quarter	Trimestre (1-4)

Variables de lag (valores pasados)

Feature	Descripción
Lag_1	Ventas de la semana anterior
Lag_2	Ventas de 2 semanas antes
Lag_4	Ventas de 4 semanas antes (aprox. 1 mes)

Medias móviles

Feature	Descripción
Rolling_Mean_4	Media móvil de 4 semanas
Rolling_Mean_12	Media móvil de 12 semanas

4.4 Limpieza final del dataset

Tras crear las features, se eliminaron las filas con valores NaN (las primeras semanas sin historial suficiente):

- **104 filas → 93 filas útiles**
- **Rango temporal final:** 2010-02-22 → 2011-12-05


4.5 Estadísticas descriptivas

Estadístico	Ventas semanales (£)
Media	187.302
Mediana	160.388
Desviación estándar	76.948
Mínimo	83.617
Máximo	483.605

Observación: la desviación estándar es alta (~41% de la media), lo que confirma la fuerte estacionalidad del negocio.

 **Figura 1:** Serie temporal de ventas semanales (2009-2011).

Archivo: 01_serie_temporal.png



5. Paso 3: Selección y entrenamiento del modelo

5.1 División train/test

Se aplicó una **división temporal** (no aleatoria) para respetar la naturaleza secuencial de los datos:

Conjunto	Semanas	Uso
Train	81 semanas	Entrenamiento del modelo
Test	12 semanas	Evaluación y predicción

Las últimas 12 semanas (septiembre – diciembre 2011) se reservaron como test, simulando el escenario real de "predecir el futuro".

5.2 Modelos evaluados

Se probaron **3 modelos** con diferentes enfoques:

5.2.1 Regresión Lineal

- **Ventaja:** modelo simple, interpretable, rápido.
- **Configuración:** parámetros por defecto de scikit-learn.

5.2.2 Árbol de Decisión

- **Ventaja:** captura relaciones no lineales.
- **Configuración:** `max_depth=5`, `random_state=42`.

5.2.3 Random Forest

- **Ventaja:** ensemble de árboles, más robusto y resistente al sobreajuste.
- **Configuración:** `n_estimators=100`, `max_depth=8`, `random_state=42`.

5.3 Features utilizadas

```
features = ['Lag_1', 'Lag_2', 'Lag_4',  
            'Rolling_Mean_4', 'Rolling_Mean_12',  
            'Month', 'WeekOfYear', 'Quarter']
```

6. Paso 4: Evaluación del modelo

6.1 Métricas

- **RMSE:** raíz del promedio de errores al cuadrado. Penaliza errores grandes.
- **MAE:** promedio de errores absolutos. Robusto frente a outliers.
- **R²:** proporción de varianza explicada. Entre -∞ y 1.

6.2 Resultados comparativos

Modelo	RMSE (£)	MAE (£)	R ²	R ² train
Regresión Lineal	50.684	42.202	-0,2225	0,890
Árbol de Decisión	59.731	51.416	-0,6979	0,956
Random Forest	46.811	41.179	-0,0428	0,926

6.3 Comparación con baselines

Modelo	RMSE (£)	MAE (£)	R ²
Baseline: Media histórica	133.987	125.902	-7,54
Baseline: Última semana	78.504	65.989	-1,93
Random Forest	46.811	41.179	-0,04

Resultado clave: mejora del 40,4% sobre el baseline de la última semana.

6.4 Interpretación del R² negativo

1. Ventana de test en campaña navideña 2011 (picos de £367.400).
2. Pocos datos para patrones anuales (2 años).
3. Estacionalidad multiplicativa difícil de capturar.
4. Sobreajuste moderado (R² train 0,926 vs test -0,04).

Conclusión: el R² negativo refleja una limitación del dataset, no invalida el modelo.

6.5 Importancia de las features

Feature	Importancia
Lag_1	~37%
Rolling_Mean_4	~30%
WeekOfYear	~19%
Lag_2	~5%
Lag_4	~4%
Rolling_Mean_12	~3%
Month	~2%
Quarter	~0,5%

Hallazgos: Lag_1 (37%) y Rolling_Mean_4 (30%) son las más relevantes. WeekOfYear (19%) captura

la estacionalidad.




Imagen: 03_importancia_features.png

Pie: Figura 2. Importancia relativa de las features en el modelo Random Forest.

6.6 Modelo seleccionado

Random Forest (n_estimators=100, max_depth=8, random_state=42)

Razones:

- Mejor RMSE, MAE y R^2 .
- Mayor generalización.
- Captura relaciones no lineales.
- Robusto frente a outliers.

7. Paso 5: Realización de predicciones

7.1 Predicciones sobre el conjunto test

Fecha	Real (£)	Predicción (£)	Error (£)	Error (%)
2011-09-19	289.258	215.267	73.991	25,58%
2011-09-26	206.326	258.653	-52.327	25,36%
2011-10-03	292.228	230.192	62.036	21,23%
2011-10-10	218.885	263.895	-45.011	20,56%
2011-10-17	263.981	209.472	54.509	20,65%
2011-10-24	232.708	268.150	-35.442	15,23%
2011-10-31	284.365	257.900	26.465	9,31%
2011-11-07	348.883	295.713	53.170	15,24%
2011-11-14	367.400	303.180	64.220	17,48%

Fecha	Real (£)	Predicción (£)	Error (£)	Error (%)
2011-11-21	303.785	305.518	-1.733	0,57% ☆
2011-11-28	299.009	309.710	-10.701	3,58% ☆
2011-12-05	290.531	305.071	-14.540	5,00% ☆

7.2 Análisis de errores

Período	Error medio
Septiembre – Octubre	~20%
Noviembre – Diciembre	~3%

El modelo captura muy bien la estacionalidad navideña.

7.3 Métricas finales

Métrica	Valor
RMSE	46.810,88 £
MAE	41.178,74 £
R ²	-0,0428

7.4 Comparación visual

El gráfico muestra que el modelo sigue la tendencia general y captura los picos navideños. En las 3 últimas semanas, las predicciones son casi idénticas a los valores reales.




Imagen: 02_predicciones_vs_realidad.png

Pie: Figura 3. Comparación entre valores reales y predicciones del modelo Random Forest.

8. Conclusiones y recomendaciones

8.1 Conclusiones técnicas

1. Random Forest es el modelo más adecuado.
2. El modelo aporta valor real (40% de mejora sobre baseline).
3. Calidad variable según período (excelente en Navidad, aceptable en transición).
4. Features más importantes: Lag_1, Rolling_Mean_4 y WeekOfYear.
5. Limitación principal: historial corto (2 años).

8.2 Recomendaciones para los mercaderes

1. **Planificación de stock en Navidad:** usar el modelo para anticipar demanda, incrementar stock un 80-100%.

2. **Reducir stock en enero-febrero:** ventas caen un 60%.
3. **Ampliar historial:** más de 3 años mejorarán la precisión.
4. **Incorporar variables externas:** promociones, meteorología, eventos.
5. **Reentrenar cada 6 meses** y monitorizar errores semanalmente.

8.3 Limitaciones

Limitación	Impacto	Mitigación
Historial corto	Dificultad con tendencias	Ampliar datos
Estacionalidad multiplicativa	R^2 negativo	Añadir promociones
Sin datos de stock	No captura roturas	Incorporar datos operativos
Sin eventos externos	No considera promociones	Añadir calendario comercial

8.4 Próximos pasos

1. Probar SARIMA, Prophet o LSTM.
2. Enriquecer dataset con más años o variables.
3. Pipeline automatizado de reentrenamiento.
4. Dashboard interactivo en Power BI.

9. Anexos

Anexo A: Estructura del proyecto

text

Reto4_Prediccion_Ventas/

```

├── datos/
│   └── online_retail_completo.csv
├── notebooks/
│   └── Reto2_JuditGiravent_Script.py
├── salidas/
│   ├── Predicciones_Reto2_JuditGiravent.csv
│   └── figuras/
│       ├── 01_serie_temporal.png
│       ├── 02_predicciones_vs_realidad.png
│       └── 03_importancia_features.png
├── docs/
│   ├── Informe_Reto2_JuditGiravent.pdf
│   └── Presentacion_Reto2_JuditGiravent.pptx
└── README.md
  
```

Anexo B: Librerías utilizadas

Librería	Versión	Uso
pandas	3.0.5	Manipulación de datos
numpy	última	Operaciones numéricas
matplotlib	3.11.2	Visualizaciones
seaborn	0.13.2	Visualizaciones estadísticas
scikit-learn	última	Modelos de ML y métricas

Anexo C: Reproducibilidad

1. Abrir el script en Google Colab.
2. Subir el dataset.
3. Ejecutar todas las celdas en orden.

Anexo D: Glosario de métricas

Métrica	Fórmula	Interpretación
---------	---------	----------------

Métrica	Fórmula	Interpretación
RMSE	$\sqrt{(\sum (y_i - \hat{y}_i)^2 / n)}$	Error en unidades de la variable objetivo
MAE	$\sum y_i - \hat{y}_i / n$	Error absoluto medio
R ²	$1 - (\sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2)$	Proporción de varianza explicada

Conclusión final

El modelo predictivo desarrollado para el Mercado de las Especies de Dataclysm demuestra que, incluso con datos limitados (2 años), la IA puede aportar valor significativo. El Random Forest seleccionado supera a los baselines simples en un 40% y logra predicciones muy precisas durante la campaña navideña.

Las recomendaciones prácticas permiten a las familias mercantes anticiparse a los vientos cambiantes del comercio y tomar decisiones informadas. Este proyecto demuestra que la IA no es magia, sino una herramienta práctica que transforma datos históricos en decisiones estratégicas.